DataTrust: ¿podemos confiar en los datos para tomar decisiones?

Auditoría de calidad de datos aplicada al mercado de alquiler turístico de Airbnb en Barcelona

Leidy Pimentel · IT Academy · Barcelona Activa — Especialización en Análisis de Datos, Proyecto final (Sprint 13) — Barcelona, noviembre de 2026

RESUMEN

Este estudio audita la calidad de los datos de Inside Airbnb Barcelona (15.293 anuncios, 1.033.523 reseñas, 5.623.190 filas de calendario) y mide si los problemas de calidad detectados cambian conclusiones de negocio y el rendimiento de un modelo predictivo, no solo cifras aisladas de nulos. Se auditaron las tres tablas con pandas y SQL (SQLite) contra tres dimensiones de calidad —completitud, integridad referencial y plausibilidad semántica—, encontrando 14 hallazgos documentados y priorizados, cada uno con una decisión de gobernanza justificada. El hallazgo central: 4.181 anuncios (31,3% de los que tienen dato) muestran un ingreso anual estimado de 0€; de ellos, 2.686 (20,1% de los que tienen dato) no son un ingreso real, sino un fallo estructural de la fórmula de Inside Airbnb cuando un anuncio no tiene reseñas recientes y tiene estancia mínima de 28 noches o más. Al corregir esto, la brecha de ingresos entre anfitriones profesionales y particulares pasa de un 39,7% aparente a un 23,1% real —una diferencia equivalente a 149.958€/año en un grupo ilustrativo de 50 anuncios—, y un modelo Random Forest, evaluado sin fuga de datos sobre una muestra común de 426 filas, mejora su R^2 de 0,347 (datos crudos) a 0,450 (datos tratados). El producto es DataTrust, un framework de auditoría–gobernanza–tratamiento–comparación aplicado aquí a Airbnb Barcelona como caso de estudio, pero generalizable a cualquier organización que tome decisiones —humanas o automatizadas— sobre datos propios sin auditarlos primero.

INTRODUCCIÓN

Los datos abiertos permiten análisis rápidos, pero raramente se verifica si son aptos para la decisión que pretenden soportar. Inside Airbnb, proyecto independiente de la empresa Airbnb, publica datos de alquiler turístico de ciudades de todo el mundo con fines de investigación y transparencia (Inside Airbnb, 2026). Que un dato de apariencia correcta —completo, sin errores evidentes— oculte un problema estructural no es una posibilidad teórica: en este mismo dataset, 4.181 anuncios (31,3% de los que tienen dato) muestran un ingreso estimado de 0€; de ellos, 2.686 (20,1% de los que tienen dato), como se demuestra en este estudio, no son un ingreso real sino un artefacto de cálculo.

Este estudio parte de la pregunta: ¿cómo afectan los problemas de calidad, consistencia e integridad de los datos a las conclusiones de negocio y al rendimiento de un modelo predictivo, en un caso real de alquiler turístico en Barcelona? Se investigan dos hipótesis de trabajo: (1) que la calidad de los datos puede cambiar las conclusiones de negocio, y (2) que el tratamiento de los datos puede cambiar el rendimiento de un modelo predictivo. Para contrastarlas, el estudio sigue un flujo de 6 pasos: auditoría de calidad, gobernanza (decisión documentada por cada hallazgo), tratamiento (curación ejecutada y verificada), comparación de negocio, comparación de modelos, y una simulación de decisión que cuantifica el impacto práctico.

METODOLOGÍA

Datos. Inside Airbnb Barcelona, snapshot del 24 de junio de 2026 (Inside Airbnb, 2026): *listings* (15.293 filas, 90 columnas), *reviews* (1.033.523 filas) y *calendar* (5.623.190 filas). **Herramientas:** Python y pandas para limpieza y análisis exploratorio; SQLite para integridad referencial, sobre todo en *calendar* por su volumen; scikit-learn (`RandomForestRegressor`, `n_estimators=200`, `random_state=42`) para el modelo predictivo.

Auditoría. Cada columna se evaluó contra tres dimensiones —completitud, integridad referencial y plausibilidad semántica—, documentando 14 hallazgos (8 en *listings*, 4 en *reviews*, 2 en *calendar*), priorizados por riesgo (alto/medio/bajo).

Gobernanza y tratamiento. Cada hallazgo recibió una de tres decisiones —cambio de datos, bandera sin modificar el valor, o mantener sin tratamiento— con su justificación. La decisión central: marcar como `revenue_no_estimable` (bandera, no eliminación) los anuncios con 0 reseñas en el último año **y** estancia mínima ≥28 noches —el patrón que impide a la fórmula de Inside Airbnb (ocupación = reseñas ÷ tasa de conversión del 50%, × duración de estancia, con tope del 70%; ingreso = ocupación × precio) estimar un ingreso (Inside Airbnb, s.f.).

Diseño experimental. Se entrenó el mismo algoritmo bajo 4 versiones: A (crudo, n=13.355), D (variables tratadas, misma población que A), B (tratado, n=10.669, excluye los 2.686 casos no estimables) y un chequeo de sensibilidad (criterio de imputación alternativo), para aislar el efecto de la población del efecto de las variables. Se detectó una fuga de datos en la comparación inicial (80% del test de B ya visto en el entrenamiento de A/D) y se corrigió restringiendo la comparación final a una muestra común de 426 filas no vistas por ningún modelo; sobre ella se aplicaron una simulación de 5.000 submuestras y un *bootstrap* de 5.000 repeticiones para cuantificar la incertidumbre.

RESULTADOS

Se presentan a continuación las cifras obtenidas, sin interpretación (véase Discusión).

Dimensión de calidad	N.º hallazgos	Identificadores
Completitud	2	L1, L2
Integridad referencial	2	R2, C1
Plausibilidad semántica	10	L3–L8, R1, R3, R4, C2

Tabla 1. Los 14 hallazgos de calidad, por dimensión evaluada (8 en listings, 4 en reviews, 2 en calendar).

Decisión de gobernanza	N.º hallazgos	Identificadores
Cambio de datos	5	L1, L2, L4, R2, C1
Bandera, sin cambiar el valor	3	L5, C2, *target*
Mantener sin tratamiento	7	L3, L6, L7, L8, R1, R3, R4

Tabla 2. Decisión aplicada a cada hallazgo (notebook 04).

Hallazgos destacados: campo `license` no verificable en el 21,1% de los anuncios, con 5.470 registros de formato roto; 6.592 filas huérfanas en *reviews* (0,64%) y 41.245 en *calendar* (0,73%); 2.686 anuncios (20,1% de los que tienen dato) marcados `revenue_no_estimable`.

	Media particular (€)	Media profesional (€)	Brecha
Sin auditar	24.338	14.678	39,7%
Auditado	28.794	22.134	23,1%

Tabla 3. Ingreso medio anual estimado por tipo de anfitrión, antes y después de excluir los 2.686 casos no estimables. Diferencia escalada a un grupo ilustrativo de 50 anuncios: 149.958€/año.

Versión del modelo	R^2	MAE (€)
A — crudo	0,347	15.168,2
D — variables tratadas	0,389	14.878,8
B — tratado	0,450	14.343,1

Tabla 4. R^2 y MAE sobre la muestra común sin fuga de datos (n=426). Bootstrap (5.000 repeticiones): diferencia A–B, IC95% [−0,2503, −0,0068] (no incluye el cero); diferencias A–D y D–B, IC95% incluyen el cero. Simulación de 5.000 submuestras: percentil del resultado real = 0,7.

DISCUSIÓN

La brecha aparente de rendimiento entre anfitriones profesionales y particulares (39,7%) se reduce casi a la mitad (23,1%) al excluir del cálculo los 2.686 anuncios cuyo ingreso de 0€ es un artefacto de la fórmula de Inside Airbnb, no un ingreso real: escalada a un grupo ilustrativo de 50 anuncios, la brecha de ingresos estimada cambia en 149.958€/año según se use el dato crudo o el auditado. Esta es la aportación concreta del estudio a la toma de decisiones empresariales: cualquier análisis —de *pricing*, de inversión o de priorización de cartera— que use `estimated_revenue_l365d` sin distinguir estos casos sobreestima sistemáticamente la brecha de rendimiento entre tipos de anfitrión, y puede derivar en decisiones basadas en una premisa incorrecta.

En el modelo predictivo, la comparación entre A, D y B sobre la muestra común sin fuga muestra una mejora progresiva de R^2 (0,347→0,389→0,450); una fuga de datos detectada y corregida durante el propio diseño del experimento confirma que el rigor metodológico debe aplicarse también al proceso de comparación, no solo a los datos de entrada. El *bootstrap* confirma que la mejora combinada de B sobre A se distingue de cero (IC95% no incluye el cero), pero los efectos de población y de variables, evaluados por separado, no se distinguen individualmente del cero con esta muestra —solo el efecto combinado (A–B) es estadísticamente real; no se puede repartir con precisión cuánto de la mejora viene de cada uno.

Limitaciones. `estimated_revenue_l365d` es una estimación de Inside Airbnb, no un ingreso real observado, y depende de una tasa de conversión de reseñas asumida del 50% (rango documentado 30,5%–72%; Inside Airbnb, s.f.) que puede sesgar segmentos con patrones de reseña distintos al turista medio. La validación sin fuga de datos usa solo 426 filas —suficiente para el efecto combinado, no para repartir con precisión población y variables por separado—. El estudio cubre un único dataset, un único algoritmo y una única variable objetivo; no se generaliza automáticamente a otros contextos.

CONCLUSIÓN

Los problemas de calidad de datos no solo existen en abstracto: cambian de forma medible tanto una decisión humana de negocio como el rendimiento de un sistema automatizado, a partir del mismo hallazgo de origen. Las dos hipótesis de partida se confirman con evidencia:

1. **Hipótesis de negocio.** La brecha de ingresos profesional–particular cambió de 39,7% a 23,1% al auditar los datos (149.958€/año en el caso ilustrativo) —un cambio de conclusión de negocio, no un ajuste cosmético.
2. **Hipótesis de modelo.** El modelo predictivo mejoró su R^2 de 0,347 a 0,450 en la única comparación sin fuga de datos disponible.

Ambas se apoyan en el mismo proceso: 14 hallazgos de calidad documentados y verificados con código real, cada uno con una decisión de gobernanza justificada, y un tratamiento ejecutado y verificado de forma reproducible (consultas de control antes/después).

La respuesta a la pregunta central es afirmativa, con matices: la calidad de los datos sí cambia conclusiones de negocio y rendimiento de modelo, pero el efecto no es uniforme —algunos hallazgos (`license`, por ejemplo) no afectan a la variable objetivo del modelo—, y el reparto exacto entre causas del efecto combinado del modelo queda como limitación abierta. DataTrust, el framework de auditoría–gobernanza–tratamiento–comparación aplicado aquí a Airbnb Barcelona, es reutilizable: sus funciones de auditoría reciben las columnas a evaluar como parámetro, no están atadas a este dataset en particular.

REFERENCIAS

Inside Airbnb. (2026). *Barcelona dataset* [Conjunto de datos]. https://insideairbnb.com/barcelona/

Inside Airbnb. (s.f.). *Data assumptions*. Recuperado el 29 de octubre de 2026, de https://insideairbnb.com/data-assumptions/